

✓ Соколов Б.О. ИУ5-23М РК1

Чтобы изменить содержимое ячейки, дважды нажмите на нее (или выберите "Ввод")

Номер варианта - 9

Номер задачи №1 - 9

Номер задачи №2 - 29

Дополнительные требования по группам:

Для студентов групп ИУ5-23М, ИУ5И-23М - для произвольной колонки данных построить график "Ящик с усами (boxplot)".

Каждая задача предполагает использование набора данных. Набор данных выбирается Вами произвольно с учетом следующих условий:

- Вы можете использовать один набор данных для решения всех задач, или решать каждую задачу на своем наборе данных.
- Набор данных должен отличаться от набора данных, который использовался в лекции для решения рассматриваемой задачи.
- Вы можете выбрать произвольный набор данных (например тот, который Вы использовали в лабораторных работах) или создать собственный набор данных (что актуально для некоторых задач, например, для задач удаления псевдоконстантных или повторяющихся признаков).
- Выбранный или созданный Вами набор данных должен удовлетворять условиям поставленной задачи. Например, если решается задача устранения пропусков, то набор данных должен содержать пропуски.

✓ Условия задач

Задача № 9

Для набора данных проведите устранение пропусков для одного (произвольного) числового признака с использованием метода заполнения "хвостом распределения".

Задача № 29

Для набора данных проведите удаление константных и псевдоконстантных признаков.

Текстовое описание датасета

В качестве датасета будем использовать набор данных, содержащий данные с информацией об автомобиле. Данный набор доступен по адресу: <https://www.kaggle.com/datasets/tawfikelmetwally/automobile-dataset>

Набор данных имеет следующие атрибуты:

- Name: Уникальный идентификатор для каждого автомобиля.
- MPG: Эффективность использования топлива измеряется в милях на галлон.
- Cylinders: количество цилиндров в двигателе.
- Displacement: объем двигателя с указанием его размера или мощности.
- Horsepower: Выходная мощность двигателя.
- Weight: Вес автомобиля.
- Acceleration: Возможность увеличения скорости, измеряемая в секундах.
- Model Year: год выпуска модели автомобиля.
- Origin: Страна или регион происхождения каждого автомобиля.

✓ Импорт библиотек

```
import numpy as np
import pandas as pd
import seaborn as sns
```

```
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Загрузка данных

```
data = pd.read_csv('Automobile.csv')
```

Первичный анализ данных

Выведем первые 5 строк датасета:

```
data.head()
```

	name	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	130.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	165.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	150.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	150.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	140.0	3449	10.5	70	usa

Далее:

[Создать код с переменной data](#)[New interactive sheet](#)

Определим размер датасета:

```
data.shape
```

```
(398, 9)
```

```
data.dtypes
```

	0
name	object
mpg	float64
cylinders	int64
displacement	float64
horsepower	float64
weight	int64
acceleration	float64
model_year	int64
origin	object

dtype: object

Проверим наличие пропусков:

```
data.isnull().sum()
```

```

      0
name      0
mpg        0
cylinders  0
displacement  0
horsepower 6
weight      0
acceleration 0
model_year  0
origin      0

dtype: int64
```

Задача № 9

Удалим колонки, содержащие пустые значения:

```
data_new_1 = data.dropna(axis=1, how='any')
(data.shape, data_new_1.shape)

((398, 9), (398, 8))
```

Выведем первые строки датасета на экран:

data_new_1

	name	mpg	cylinders	displacement	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	3449	10.5	70	usa
...	...	...	...	...	...	...	...	...
393	ford mustang gl	27.0	4	140.0	2790	15.6	82	usa
394	vw pickup	44.0	4	97.0	2130	24.6	82	europa
395	dodge rampage	32.0	4	135.0	2295	11.6	82	usa
396	ford ranger	28.0	4	120.0	2625	18.6	82	usa
397	chevy s-10	31.0	4	119.0	2720	19.4	82	usa

398 rows x 8 columns

Далее: [Создать код с переменной data_new_1](#) [New interactive sheet](#)

Удалим строки, содержащие пустые значения:

```
data_new_2 = data.dropna(axis=0, how='any')
(data.shape, data_new_2.shape)

((398, 9), (392, 9))
```

```
data_new_2.head()
```

	name	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	130.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	165.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	150.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	150.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	140.0	3449	10.5	70	usa

Далее: [Создать код с переменной data_new_2](#) [New interactive sheet](#)

Найдем значение квантиля для заполнения пропущенных значений:

```
quantile_value = data_new_2['horsepower'].quantile(0.95)
```

Замена пропущенных значений на значение из хвоста распределения:

```
data_new_2['horsepower'] = data_new_2['horsepower'].fillna(quantile_value)
```

```
/tmp/ipykernel_32799/2342498556.py:1: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead
```

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view

```
data_new_2['horsepower'] = data_new_2['horsepower'].fillna(quantile_value)
```

Выведем на экран:

```
data_new_2.head()
```

	name	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	130.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	165.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	150.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	150.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	140.0	3449	10.5	70	usa

Далее: [Создать код с переменной data_new_2](#) [New interactive sheet](#)

```
data_new_2.isnull().sum()
```

```

      0
name    0
mpg     0
cylinders 0
displacement 0
horsepower 0
weight    0
acceleration 0
model_year 0
origin    0

dtype: int64
```

✓ Задача № 29

Выведем первые 20 строк:

```
data.head(20)
```

	name	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	130.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	165.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	150.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	150.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	140.0	3449	10.5	70	usa
5	ford galaxie 500	15.0	8	429.0	198.0	4341	10.0	70	usa
6	chevrolet impala	14.0	8	454.0	220.0	4354	9.0	70	usa
7	plymouth fury iii	14.0	8	440.0	215.0	4312	8.5	70	usa
8	pontiac catalina	14.0	8	455.0	225.0	4425	10.0	70	usa
9	amc ambassador dpl	15.0	8	390.0	190.0	3850	8.5	70	usa
10	dodge challenger se	15.0	8	383.0	170.0	3563	10.0	70	usa
11	plymouth 'cuda 340	14.0	8	340.0	160.0	3609	8.0	70	usa
12	chevrolet monte carlo	15.0	8	400.0	150.0	3761	9.5	70	usa
13	buick estate wagon (sw)	14.0	8	455.0	225.0	3086	10.0	70	usa
14	toyota corona mark ii	24.0	4	113.0	95.0	2372	15.0	70	japan
15	plymouth duster	22.0	6	198.0	95.0	2833	15.5	70	usa
16	amc hornet	18.0	6	199.0	97.0	2774	15.5	70	usa
17	ford maverick	21.0	6	200.0	85.0	2587	16.0	70	usa
18	datsum pl510	27.0	4	97.0	88.0	2130	14.5	70	japan
19	volkswagen 1131 deluxe sedan	26.0	4	97.0	46.0	1835	20.5	70	europa

Далее: [Создать код с переменной data](#) [New interactive sheet](#)

Анализ константных и псевдоконстантных признаков:

```
constant_features = [feat for feat in data.columns if data[feat].nunique() == 1]
pseudo_constant_features = [feat for feat in data.columns if data[feat].value_counts(normalize=True).values[0] > 0.99]
```

Удаление константных и псевдоконстантных признаков:

```
data.drop(columns=constant_features + pseudo_constant_features, inplace=True)
```

Выведем полученный результат:

data.head()

	name	mpg	cylinders	displacement	horsepower	weight	acceleration	model_year	origin
0	chevrolet chevelle malibu	18.0	8	307.0	130.0	3504	12.0	70	usa
1	buick skylark 320	15.0	8	350.0	165.0	3693	11.5	70	usa
2	plymouth satellite	18.0	8	318.0	150.0	3436	11.0	70	usa
3	amc rebel sst	16.0	8	304.0	150.0	3433	12.0	70	usa
4	ford torino	17.0	8	302.0	140.0	3449	10.5	70	usa

Далее: [Создать код с переменной data](#) [New interactive sheet](#)


Отображение в виде "Ящика с усами":

```
plt.figure(figsize=(8, 4))
sns.set_style("whitegrid")
ax = sns.boxplot(x='model_year', data=data, palette='Set2')
ax.set_xlabel('Model Year')
ax.set_ylabel('Value')
ax.set_title('Распределение Model Year (Boxplot)')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

/tmp/ipykernel_32799/2866173287.py:3: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and

```
ax = sns.boxplot(x='model_year', data=data, palette='Set2')
```



```
plt.figure(figsize=(8, 4))
sns.set_style("whitegrid")
ax = sns.boxplot(x='cylinders', y='horsepower', data=data, palette='Set2')
ax.set_xlabel('Number of Cylinders')
ax.set_ylabel('Horsepower')
ax.set_title('Horsepower Distribution by Number of Cylinders')
plt.tight_layout()
plt.show()
```

/tmp/ipykernel_32799/3965511848.py:3: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and

```
ax = sns.boxplot(x='cylinders', y='horsepower', data=data, palette='Set2')
```

